

Analisi esplorativa del tasso di suicidi in diversi paesi tra il 2014 e il 2019

Tesina di Data Science for Health Systems

Paolo Speziali

*Dipartimento di Ingegneria
Università degli Studi di Perugia
Perugia, Italia
paolo.speziali@studenti.unipg.it*

Abstract—Questo documento riporta i risultati dell'analisi esplorativa del dataset fornito dalla World Health Organization relativo al tasso di mortalità per suicidio standardizzato per età. L'obiettivo di questa analisi è quello di esaminare se, in differenti paesi tra il 2014 e il 2019, la distribuzione del tasso di suicidi sia significativamente differente o meno, aprendo la strada a potenziali ipotesi su fenomeni globali che possano averne influenzato la tendenza. Tramite l'analisi di tre gruppi distinti è possibile osservare come una distribuzione senza differenze significative emerga solo in pochi casi.

Index Terms—suicide, EDA, WHO, GDP

I. INTRODUZIONE

Il suicidio è definito come l'atto di terminare intenzionalmente la propria vita [1]. Come accade da decenni, il suicidio rimane una delle cause più frequenti di morte nel mondo occidentale [2]. Il Dr. Peeter Värnik dell'*Estonian-Swedish Mental Health and Suicidology Institute*, nel suo paper "Suicide in the World" [3], osserva che: "Il suicidio è un atto individuale ma, una volta che i dati sono aggregati a livello di paese, le variazioni da un anno all'altro sono piuttosto ridotte e di solito non ci sono grandi fluttuazioni. Si è tentati di affermare che il miglior predittore del tasso di suicidi nel breve periodo è il tasso di suicidi del passato. Tuttavia, nel lungo periodo possono verificarsi e si sono verificati grandi cambiamenti". Nello studio che segue andremo ad osservare i cambiamenti nel tasso di suicidio a livello mondiale tra il 2014 e il 2019 e verificare se è possibile affermare che non esistono differenze significative nella distribuzione tassi di suicidio tra paesi differenti.

II. DATASET

A. Descrizione del dataset

Il dataset utilizzato proviene dal portale web della World Health Organization (WHO) ed ha come titolo "Age-standardized suicide rates (per 100000 population)" [4]. Contiene dati riguardanti i tassi di suicidi in ogni paese dal 2000 al 2019 di soggetti maschili, femminili e di entrambi i sessi. Tali dati sono standardizzati prendendo in considerazione la distribuzione dell'età della popolazione del paese, è stato scelto questo dataset rispetto a "Crude suicide rates (per 100000

population)" in quanto la standardizzazione rispetto all'età dà luogo a statistiche più rappresentative quando l'evento preso in considerazione non è raro [5]. I dati sono stati acquisiti attraverso il processo di censimento della popolazione, registrazioni anagrafiche e l'analisi di certificati medici contenenti informazioni sulla causa dei decessi. Il dataset originale si compone di 10980 campioni e 34 feature, di cui molte con valori totalmente nulli o non importati ai fini della nostra analisi.

B. Modellazione del dataset

Prima di iniziare con l'analisi esplorativa il dataset è stato ridotto di dimensione andando a prendere unicamente le feature d'interesse qui di seguito riportate:

- **ParentLocation**, rinominato in **WorldRegion**: indica l'area geografica a cui appartiene il paese relativo al dato in esame secondo la divisione fatta dal WHO;
- **SpatialDimValueCode**, rinominato in **CountryCode**: indica il codice a tre lettere maiuscole associato al paese relativo al dato in esame (es. Italia sarà associato ad ITA);
- **Location**, rinominato in **Country**: indica il nome del paese relativo al dato in esame;
- **Period**, rinominato in **Year**: anno in cui è stato registrato il dato in esame;
- **Dim1**, rinominato in **Sex**: indica il sesso (Male, Female o Both Sexes) relativo al dato in esame;
- **FactValueNumeric**, rinominato in **Value**: tasso di suicidi registrato per quel sesso in quell'anno e in quel paese;

Con le colonne sopracitate selezionate nel dataset non sono presenti valori nulli o non significativi. Successivamente il dataset è stato nuovamente modificato per avere un'unica entry per ogni anno relativo a un paese, suddividendo la feature Sex in tre feature diverse contenenti ognuna il valore associato nel campo Value, la struttura finale è di seguito riportata:

- **WorldRegion**;
- **CountryCode**;
- **Country**;
- **Year**;
- **Male**: Value associato al tasso di suicidio maschile;

- **Female:** Value associato al tasso di suicidio femminile;
- **Both:** Value associato al tasso di suicidio di entrambi i sessi;

III. ANALISI ESPLORATIVA

In questa sezione di analisi esplorativa dei dati (EDA) andremo dapprima ad analizzare tramite strumenti di visualizzazione dei dati il quadro generale della situazione per poi soffermarci su cinque gruppi di “soggetti”. Vedremo in seguito con quale criterio sono stati selezionati e a quali conclusioni ci permettono di arrivare.

A. Il quadro generale

Inizialmente è stata studiata la distribuzione dei valori Sex rispetto al sesso (Male e Female) di appartenenza tramite il boxplot in Fig. 1. In questo modo è possibile apprezzare come




Fig. 1. Boxplot della distribuzione dei valori rispetto al sesso

esista una notevole differenza nella distribuzione tra i sessi: è evidente come i soggetti maschili siano i più colpiti da questo fenomeno.




Fig. 2. Lineplot del trend dei suicidi medi globali ogni anno

Ciò è apprezzabile anche andando a vedere il trend globale dei valori medi dei tassi di suicidio ogni anno in Fig. 2: il trend maschile si trova su valori significativamente più alti rispetto a quello femminile, il trend di Both si pone, prevedibilmente, a cavallo tra i due.

Un'ulteriore osservazione che è possibile fare è che, nonostante il trend globale sia in declino, non c'è una differenza particolarmente significativa da anno ad anno. Possiamo apprezzare meglio ciò osservando la distribuzione dei valori anno per anno tramite il boxplot in Fig. 3. La differenza tra un anno




Fig. 3. Boxplot della distribuzione dei valori tra gli anni

gli adiacenti è poca ma esiste, nel corso del ventennio in esame infatti la distribuzione cambia notevolmente. Andiamo infine ad analizzare il trend del tasso dei suicidi medio suddiviso per regione del mondo secondo la divisione del WHO in Fig. 4.




Fig. 4. Lineplot del trend dei suicidi medi ogni anno suddiviso per regione globale

Possiamo vedere come ci sia in tutte le regioni un trend comune di declino e persino alcuni trend di crescita e decrescita comuni (ad esempio nel 2008-2009). A questo punto ci si potrebbe chiedere se alcuni gruppi di paesi o persino le

regioni globali abbiano distribuzioni di tassi di suicidi senza differenze significative.

Andiamo ora ad analizzare un primo gruppo, formato dalle sei regioni globali e dalle loro medie annuali e poi tre gruppi formati ognuno da sei paesi differenti selezionati con diversi criteri. Per semplificare l'analisi e ridurre il numero di grafici verranno presi in esame solo gli anni dal 2014 al 2019.

B. Primo gruppo - Regioni globali (WR)

Utilizziamo il Box and Whisker Plot (BWPlot) in Fig. 5 per visualizzare il valor medio di Both in ogni regione del mondo, anno per anno. Già dalla figura è possibile vedere che, a parte




Fig. 5. BWPlot della media di Both anno per anno in ogni regione

il declino globale, non viene seguito un vero e proprio trend comune. Tramite gli otto QQ-Plot in Fig. 6, uno per anno, si può osservare come sia molto probabile che la media dei dati raccolti ogni anno seguano una distribuzione normale.

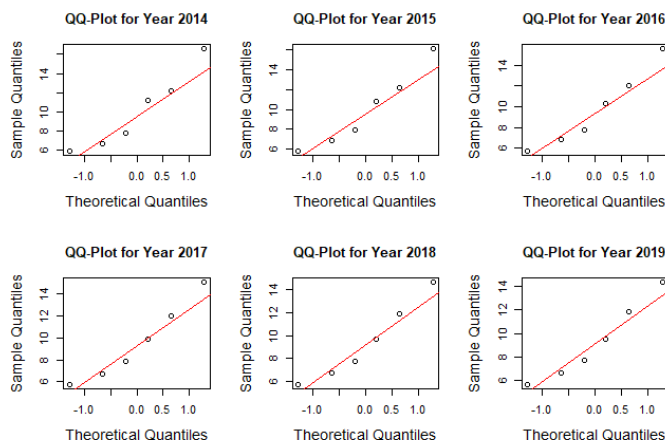


Fig. 6. QQ-Plot dei valori medi di Both negli anni presi in esame

C. Secondo gruppo - Paese con PIL più alto per WR

I paesi individuati come quelli con il PIL maggiore [6] per la WR d'appartenenza nel 2019 sono:

- **United States of America (USA)** per Americas;
- **Germany (DEU)** per Europe;
- **China (CHN)** per Western Pacific;
- **Saudi Arabia (SAU)** per Eastern Mediterranean;
- **Nigeria (NGA)** per Africa;
- **India (IND)** per South-East Asia.

Dati questi paesi osserviamo il BWPlot relativo in Fig. 7. Qua un trend comune appare tra alcuni soggetti mentre tra




Fig. 7. BWPlot di Both anno per anno in ogni paese (2° gruppo)

altri appare di meno, in seguito verificheremo con un test consono se le distribuzioni differiscono significativamente o meno. Tramite gli otto QQ-Plot in Fig. 8, uno per anno, si può osservare come, anche qua, sia molto probabile che i dati raccolti ogni anno seguano una distribuzione normale.

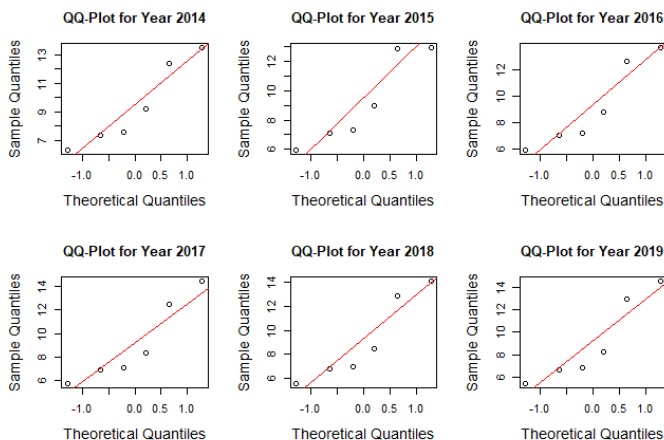


Fig. 8. QQ-Plot dei valori Both negli anni presi in esame (2° gruppo)

D. Terzo gruppo - Paesi con tasso di suicidio più alto in assoluto

I paesi individuati come quelli con il tasso di suicidio più alto in assoluto sono:

- **Lesotho (LSO)**;

- **Guyana (GUY);**
- **Russian Federation (RUS);**
- **Eswatini (SWZ);**
- **Botswana (BWA);**
- **Kiribati (KIR);**

Dati questi paesi osserviamo il BWPlot relativo in Fig. 9. Qua




Fig. 9. BWPlot di Both anno per anno in ogni paese (3° gruppo)

è difficile individuare un trend comune. Nei QQ-Plot in Fig. 10 vediamo come i dati non saranno probabilmente distribuiti normalmente negli anni.

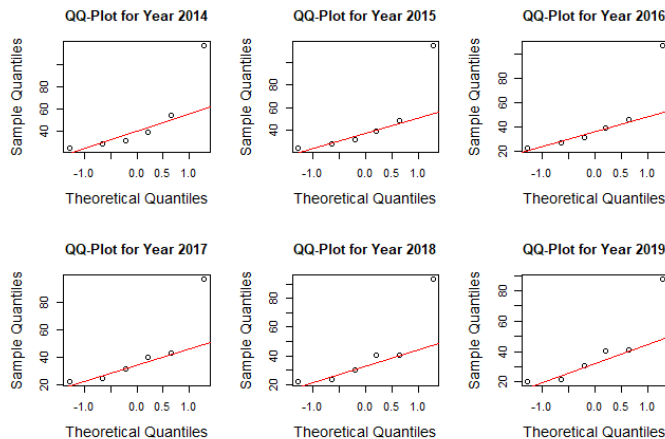


Fig. 10. QQ-Plot dei valori Both negli anni presi in esame (3° gruppo)

E. Quarto gruppo - Paesi con tasso di suicidio più alto per WR

I paesi individuati come quelli con il tasso di suicidio più alto per la WR d'appartenenza sono:

- **Lesotho (LSO)** per Africa;
- **Guyana (GUY)** per Americas;
- **Russian Federation (RUS)** per Europe;
- **Somalia (SOM)** per Eastern Mediterranean;
- **Sri Lanka (LKA)** per South-East Asia;

- **Kiribati (KIR)** per Western Pacific;
- Dati questi paesi osserviamo il BWPlot relativo in Fig. 11. Qua




Fig. 11. BWPlot di Both anno per anno in ogni paese (4° gruppo)

un trend comune è già più probabile. Nei QQ-Plot in Fig. 12 vediamo come i dati non saranno probabilmente distribuiti normalmente negli anni.

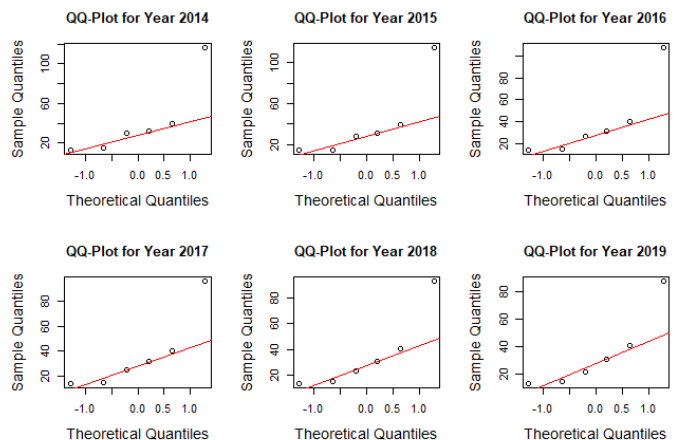


Fig. 12. QQ-Plot dei valori Both negli anni presi in esame (4° gruppo)

IV. TEST STATISTICS

Vogliamo verificare che, all'interno dei gruppi selezionati, i dati raccolti provengano da distribuzioni che non differiscono in maniera significativa. Per fare ciò una buona scelta è l'ANOVA a misure ripetute, tuttavia è necessario andare a verificare la normalità, l'omocedasticità e la sfericità delle misure, in caso anche una sola di queste assunzioni non venga rispettata occorre ripiegare sul test non parametrico di Friedman.

A. Verifica della normalità

Le supposizioni sulla normalità dei dati vengono confermate con il test di Shapiro-Wilk, i cui p-value vengono riportati nella Tab. I. Solo i primi due gruppi presi in esame (gruppo delle

medie delle WR e dei paesi con PIL più alto per WR) infatti rispettano il vincolo della normalità in quanto hanno tutti i p-value dei test relativi ai loro anni superiori al valore di 0.05.

TABLE I
TEST DI SHAPIRO-WILK

Gruppo	Anni					
	2014	2015	2016	2017	2018	2019
Gruppo 1	0.531	0.672	0.690	0.705	0.708	0.719
Gruppo 2	0.913	0.824	0.804	0.832	0.746	0.569
Gruppo 3	0.018	0.011	0.017	0.026	0.021	0.056
Gruppo 4	0.015	0.011	0.018	0.037	0.046	0.071

B. Verifica dell'omoschedasticità

In quanto solo i primi due gruppi hanno dati distribuiti secondo una distribuzione normale andremo ad utilizzare il test di Bartlett solo su questi due, i risultati, riportati in Tab. II mostrano come entrambi rispettino l'omoschedasticità.

TABLE II
TEST DI BARTLETT

Gruppo	K-squared	p-value
Gruppo 1	0.27014	0.9982
Gruppo 2	0.39744	0.9954

Discorso analogo possiamo fare per gli ultimi due gruppi per cui è stato utilizzato il test di Levene, più robusto rispetto a Bartlett nel caso di allontanamento dalla normalità. Come si può vedere in Tab. III, anche loro sono omoschedastici.

TABLE III
TEST DI LEVENE

Gruppo	F-value	p-value
Gruppo 3	0.037	0.9992
Gruppo 4	0.016	0.9999

C. Verifica della sfericità

Utilizzando la statistica di Greenhouse-Geisser verifichiamo che nessuno dei quattro gruppi soddisfa la sfericità in quanto i loro valori ϵ , riportati in Tab. IV, si allontanano troppo da 1. Possiamo però pensare di utilizzare comunque

TABLE IV
STATISTICA DI GREENHOUSE-GEISSER

Gruppo	ϵ
Gruppo 1	0.2067
Gruppo 2	0.2280
Gruppo 3	0.2122
Gruppo 4	0.2028

ANOVA per i primi due gruppi che soddisfano sia normalità che omoschedasticità, almeno per vedere se essa conferma Friedman o meno (in ogni caso, sarà il test di Friedman quello che considereremo significativo).

D. Test di Friedman

Per i vari gruppi riportiamo, nella Tab. V, i risultati del test di Friedman. Possiamo osservare come solo nel secondo

TABLE V
TEST DI FRIEDMAN

Gruppo	χ -squared	p-value
Gruppo 1	26.19	8.196×10^{-5}
Gruppo 2	10.762	0.05631
Gruppo 3	13.143	0.02208
Gruppo 4	8.2857	0.1412

e quarto gruppo (ovvero quello dei paesi con PIL più alto per WR e paesi con suicidio più alto per WR) il p-value supera il valore di 0.05 e quindi possiamo accettare l'ipotesi nulla, ovvero quella per cui non esistono differenze statistiche significative all'interno di tali gruppi. Ciò andrebbe a confermare quel che si poteva leggermente intuire dai BWPlot mostrati per questi due gruppi. Nel primo gruppo, ovvero quello composto dalle sei WR e dai rispettivi tassi di suicidio medi per anno, il p-value è molto più basso rispetto agli altri, indice che le differenze significative esistono. Andando a fare su questo gruppo il test di Wilcoxon coppia a coppia con la correzione di Benjamini-Hochberg, i cui p-value sono riportati in Tab. VI possiamo osservare come differenze significative si presentino in quasi ogni coppia di anni messa a confronto.

TABLE VI
TEST DI WILCOXON CON CORREZIONE DI BENJAMINI-HOCHBERG

Anni	2014	2015	2016	2017	2018
2015	0.438	-	-	-	-
2016	0.108	0.043	-	-	-
2017	0.078	0.043	0.438	-	-
2018	0.043	0.043	0.043	0.043	-
2019	0.043	0.043	0.043	0.043	0.043

E. ANOVA a misure ripetute

Il primo e il secondo gruppo non rispettano le supposizioni per l'ANOVA a misure ripetute unicamente perché si allontanano dalla sfericità. Visti i risultati del test di Friedman, vediamo se l'ANOVA a misure ripetute li conferma o meno. In Tab. VII Vediamo come per entrambi i gruppi l'ANOVA

TABLE VII
ANOVA A MISURE RIPETUTE

Gruppo	F-value	p-value
Gruppo 1	4.482	0.0878
Gruppo 2	0.229	0.652

ci dia un p-value superiore allo 0.05, nel secondo gruppo, in cui accettiamo l'ipotesi nulla anche con il test di Friedman, otteniamo persino uno 0.652. Nel primo gruppo ci troviamo sopra la soglia con uno 0.0878, con ANOVA quindi accettiamo l'ipotesi nulla per cui, con Friedman, avevamo una fortissima evidenza contro. Data però la sfericità non rispettata, i risultati ottenuti con l'ANOVA sono molto meno significativi.

V. CONCLUSIONI

Dall'analisi appena presentata possiamo osservare come, in determinati periodi di tempo e in determinati gruppi, in questo caso quello dei paesi più ricchi per ogni regione e quello dei paesi con tasso di suicidio più alto per ogni regione, non esistano differenze significative nella distribuzione del tasso dei suicidi. Tuttavia, anche solo il prendere in esame due gruppi con quattro paesi uguali ma due diversi ci restituisce risultati completamente differenti (ad esempio quanto visto col terzo e quarto gruppo). Data la particolarità del fenomeno che può essere attribuito alle motivazioni più disparate, questa analisi si propone come base per studi futuri, magari andando ad unire questo dataset con altri dataset che descrivono fattori sociali o geopolitici che potrebbero essere caratterizzanti per quanto riguarda la distribuzione del tasso dei suicidi.

REFERENCES

- [1] Shneidman ES. "The definition of suicide". New York, NY and London: John Wiley and sons; 1985.
- [2] Gvion Y, Apter A. "Suicide and suicidal behavior". Public Health Reviews. 2012;34: epub ahead of print.
- [3] Värnik, P. "Suicide in the world". Int. J. Environ. Res. Public Health 2012, 9, 760-771. <https://doi.org/10.3390/ijerph9030760>
- [4] World Health Organization. (2023). "Suicide rates". Recuperato da <https://www.who.int/data/gho/data/themes/mental-health/suicide-rates>
- [5] Statistics Canada. (2023). "Age-standardized rates". Recuperato da <https://www.statcan.gc.ca/en/dai/btd/asr>
- [6] countryeconomy.com. (2023). "GDP - Gross Domestic Product 2019". Recuperato da <https://countryeconomy.com/gdp?year=2019>